第 9 章

問 1

実数 $a_i, b_i (i=1, \dots, n)$, x に対して x の 2 次方程式 $\sum_{i=1}^{n}(a_i x - b_i)^2 = 0$ を考える．左辺が 0 以上だから解は多くても 1 つのみである．

$$\sum_{i=1}^{n}(a_i x - b_i)^2 = \left(\sum_{i=1}^{n} a_i^2\right)x^2 - 2\left(\sum_{i=1}^{n} a_i b_i\right)x + \sum_{i\sim 1}^{n} b_i^2 = 0$$

となるから，判別式について

$$\left(\sum_{i=1}^{n} a_i b_i\right)^2 - \left(\sum_{i=1}^{n} a_i^2\right)\left(\sum_{i=1}^{n} b_i^2\right) \leq 0$$

となり，コーシー・シュワルツの不等式が成り立つ．等号成立は $b_i = a_i x$ となるような x が存在するときである．

2 つの変数 x, y に対し，観測値 (x_i, y_i) $(i=1, \dots, n)$ が得られたとする．また，x, y の平均値をそれぞれ $\overline{x}, \overline{y}$ で表す．$a_i = x_i - \overline{x}, b_i = y_i - \overline{y}$ としてコーシー・シュワルツの不等式を用いると

$$\left(\sum_{i=1}^{n}(x_i - \overline{x})^2\right)\left(\sum_{i=1}^{n}(y_i - \overline{y})^2\right) \geq \left(\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})\right)^2$$

となり，

$$\frac{\left(\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})\right)^2}{\left(\sum_{i=1}^{n}(x_i - \overline{x})^2\right)\left(\sum_{i=1}^{n}(y_i - \overline{y})^2\right)} \leq 1$$

が得られる．左辺は相関係数 r の 2 乗だから，$-1 \leq r \leq 1$ が成り立つ．

問 2

x_i の順位を r_i，y_i の順位を s_i とする $(i=1, \dots, n)$．$\{r_i : i=1, \dots, n\}$ と $\{s_i : i=1, \dots, n\}$ はどちらも $\{1, 2, \dots, n\}$ であることに注意する．

$$\sum_{i=1}^{n} r_i = \sum_{i=1}^{n} s_i = 1 + 2 + \cdots + n = \frac{1}{2}n(n+1)$$

だから，順位の平均は $\overline{r} = \overline{s} = (n+1)/2$ となる．r の分散は

$$\frac{1}{n}\sum_{i=1}^{n}(r_i - \overline{r})^2 = \frac{1}{n}\sum_{i=1}^{n} r_i^2 - \overline{r}^2 = \frac{1}{n}\cdot\frac{1}{6}n(n+1)(2n+1) - \left\{\frac{1}{2}(n+1)\right\}^2 = \frac{1}{12}(n+1)(n-1)$$

となり，s の分散も同じ結果となる．$d_i = r_i - s_i$ を用いると，r と s の共分散は

$$\frac{1}{n}\sum_{i=1}^{n} r_i s_i - \overline{r}\,\overline{s} = -\frac{1}{2n}\sum_{i=1}^{n}(r_i - s_i)^2 + \frac{1}{n}\sum_{i=1}^{n} r_i^2 - \overline{r}^2$$

$$= -\frac{1}{2n}\sum_{i=1}^{n} d_i^2 + \frac{1}{12}(n+1)(n-1)$$

と表すことができる．r と s に対するピアソンの相関係数を考えると

$$\frac{-\frac{1}{2n}\sum_{i=1}^{n}d_i^2+\frac{1}{12}(n+1)(n-1)}{\frac{1}{12}(n+1)(n-1)}=1-\frac{6\sum_{i=1}^{n}d_i^2}{n(n^2-1)}$$

が得られる．

問 3

$E[X]=\mu_X, E[Y]=\mu_Y, E[Z]=\mu_Z$ と表す．

① $E[aX+b]=a\mu_X+b, E[cY+d]=c\mu_Y+d$ だから，共分散の定義より

$$\begin{aligned}Cov[aX+b, cY+d]&=E[\{(aX+b)-(a\mu_X+b)\}\{(cY+d)-(c\mu_Y+d)\}]\\&=E[ac(X-\mu_X)(Y-\mu_Y)]\\&=acCov[X, Y]\end{aligned}$$

② $E[X+Y]=\mu_X+\mu_Y$ だから，共分散の定義より

$$\begin{aligned}Cov[X+Y, Z]&=E[(X+Y)Z]-E[X+Y]E[Z]\\&=E[XZ+YZ]-(\mu_X+\mu_Y)\mu_Z\\&=E[XZ]-\mu_X\mu_Z+E[YZ]-\mu_Y\mu_Z\\&=Cov[X, Z]+Cov[Y, Z]\end{aligned}$$

③ $V[X]=E[X^2]-\mu_X^2$ が成り立つことを用いると

$$\begin{aligned}V[X+Y]&=E[(X+Y)^2]-(E[X+Y])^2\\&=E[X^2+2XY+Y^2]-(\mu_X+\mu_Y)^2\\&=E[X^2]-\mu_X^2+E[Y^2]-\mu_Y^2+2(E[XY]-\mu_X\mu_Y)\\&=V[X]+V[Y]+2Cov[X, Y]\end{aligned}$$

問 4

式(9-4) で

$$\hat{\beta}_1=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sum_{i=1}^{n}(x_i-\bar{x})^2}=\frac{s_{xy}}{s_x^2}$$

と与えられている．ここで s_{xy} は x と y の共分散，s_x は x の標準偏差である．y の標準偏差を s_y として，相関係数 r は

$$r=\frac{s_{xy}}{s_x s_y}$$

と表すことができるから，

$$\hat{\beta}_1=\frac{s_{xy}}{s_x s_y}\frac{s_y}{s_x}=r\frac{s_y}{s_x}$$

問 5

まず傾きの推定値 $\hat{\beta}_1$ について考える．$\sum_{i=1}^{n}(x_i-\bar{x})=0$ であることを用いると

$$\hat{\beta}_1=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sum_{i=1}^{n}(x_i-\bar{x})^2}=\frac{\sum_{i=1}^{n}(x_i-\bar{x})y_i-\bar{y}\sum_{i=1}^{n}(x_i-\bar{x})}{\sum_{i=1}^{n}(x_i-\bar{x})^2}=\frac{\sum_{i=1}^{n}(x_i-\bar{x})y_i}{\sum_{i=1}^{n}(x_i-\bar{x})^2}$$

となり，y_i の線形和の形になるので，

$$E[\hat{\beta}_1]=\frac{\sum_{i=1}^{n}(x_i-\bar{x})E[y_i]}{\sum_{i=1}^{n}(x_i-\bar{x})^2}=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(\beta_0+\beta_1x_i)}{\sum_{i=1}^{n}(x_i-\bar{x})^2}=\beta_0\frac{\sum_{i=1}^{n}(x_i-\bar{x})}{\sum_{i=1}^{n}(x_i-\bar{x})^2}+\beta_1\frac{\sum_{i=1}^{n}(x_i-\bar{x})x_i}{\sum_{i=1}^{n}(x_i-\bar{x})^2}$$

ここで $\sum_{i=1}^{n}(x_i-\bar{x})=0$ より第 1 項は 0 となり，第 2 項では $\sum_{i=1}^{n}(x_i-\bar{x})x_i=\sum_{i=1}^{n}(x_i-\bar{x})^2$ となるので，$E[\hat{\beta}_1]=\beta_1$ が成り立つ．分散については，y_i はすべて互いに独立だから

$$V[\hat{\beta}_1]=\frac{\sum_{i=1}^{n}(x_i-\bar{x})^2V[y_i]}{\left\{\sum_{i=1}^{n}(x_i-\bar{x})^2\right\}^2}=\sigma^2\frac{\sum_{i=1}^{n}(x_i-\bar{x})^2}{\left\{\sum_{i=1}^{n}(x_i-\bar{x})^2\right\}^2}=\frac{\sigma^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}$$

となる．

切片の推定値 $\hat{\beta}_0$ については，

$$\bar{y}=\frac{1}{n}\sum_{i=1}^{n}(\beta_0+\beta_1x_i+\varepsilon_i)=\beta_0+\beta_1\bar{x}+\frac{1}{n}\sum_{i=1}^{n}\varepsilon_i$$

と表せることから

$$E[\hat{\beta}_0]=E[\bar{y}]-E[\hat{\beta}_1]\bar{x}=\beta_0+\beta_1\bar{x}-\beta_1\bar{x}=\beta_0$$

となる．分散については，$\hat{\beta}_0$ を

$$\hat{\beta}_0=\bar{y}-\hat{\beta}_1\bar{x}=\frac{1}{n}\sum_{i=1}^{n}y_i-\frac{\sum_{i=1}^{n}(x_i-\bar{x})y_i}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\cdot\bar{x}=\sum_{i=1}^{n}\left\{\frac{1}{n}-\frac{(x_i-\bar{x})\bar{x}}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right\}y_i$$

と表すと

$$V[\hat{\beta}_0]=\sum_{i=1}^{n}\left\{\frac{1}{n}-\frac{(x_i-\bar{x})\bar{x}}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right\}^2V[y_i]=\sigma^2\sum_{i=1}^{n}\left\{\frac{1}{n}-\frac{(x_i-\bar{x})\bar{x}}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right\}^2$$

となる．ここで

$$\sum_{i=1}^{n}\left\{\frac{1}{n}-\frac{(x_i-\bar{x})\bar{x}}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right\}^2$$

$$= \sum_{i=1}^{n} \left\{ \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2 - n(x_i - \bar{x})\bar{x}}{n \sum_{i=1}^{n} (x_i - \bar{x})^2} \right\}^2$$

$$= \frac{1}{\left\{ n \sum_{i=1}^{n} (x_i - \bar{x})^2 \right\}^2} \left[n \left\{ \sum_{i=1}^{n} (x_i - \bar{x})^2 \right\}^2 - 2n\bar{x} \sum_{i=1}^{n} (x_i - \bar{x}) \sum_{i=1}^{n} (x_i - \bar{x})^2 + n^2 \bar{x}^2 \sum_{i=1}^{n} (x_i - \bar{x})^2 \right]$$

$$= \frac{1}{\left\{ n \sum_{i=1}^{n} (x_i - \bar{x})^2 \right\}^2} \left[n \left\{ \sum_{i=1}^{n} (x_i - \bar{x})^2 \right\}^2 + n^2 \bar{x}^2 \sum_{i=1}^{n} (x_i - \bar{x})^2 \right]$$

$$= \frac{1}{n \sum_{i=1}^{n} (x_i - \bar{x})^2} \left[\sum_{i=1}^{n} (x_i - \bar{x})^2 + n\bar{x}^2 \right]$$

$$= \frac{1}{n \sum_{i=1}^{n} (x_i - \bar{x})^2} \sum_{i=1}^{n} x_i^2$$

となるから，

$$V[\hat{\beta}_0] = \frac{\sigma^2 \sum_{i=1}^{n} x_i^2}{n \sum_{i=1}^{n} (x_i - \bar{x})^2}$$

が得られる．

問 6

y の全平方和は

$$\sum_{i=1}^{n} (y_i - \bar{y})^2 = \sum_{i=1}^{n} \{(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})\}^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 + \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2 + 2\sum_{i=1}^{n} (y_i - \hat{y}_i)(\hat{y}_i - \bar{y})$$

と分解することができる．ここで $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$ だから，

$$\sum_{i=1}^{n} (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) = \hat{\beta}_1 \sum_{i=1}^{n} \hat{\varepsilon}_i (x_i - \bar{x}) \quad = \hat{\beta}_1 \left[\sum_{i=1}^{n} \hat{\varepsilon}_i x_i - \bar{x} \sum_{i=1}^{n} \hat{\varepsilon}_i \right]$$

となる．$\sum_{i=1}^{n} \hat{\varepsilon}_i = \sum_{i=1}^{n} \hat{\varepsilon}_i x_i = 0$（第 9 章脚注 7）より

$$\sum_{i=1}^{n} (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) = 0$$

となるから，

$$\sum_{i=1}^{n} (y_i - \bar{y})^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 + \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2$$

が成り立つ．

問 7

式(9-7) から,

$$Cov[\bar{y}, \hat{\beta}_1] = Cov\left[\bar{y}, \frac{\sum_{i=1}^{n}(x_i-\bar{x})y_i}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right] = \frac{1}{n\sum_{i=1}^{n}(x_i-\bar{x})^2} Cov\left[\sum_{i=1}^{n} y_i, \sum_{i=1}^{n}(x_i-\bar{x})y_i\right]$$

となり，右辺の共分散は

$$Cov\left[\sum_{i=1}^{n} y_i, \sum_{i=1}^{n}(x_i-\bar{x})y_i\right] = \sum_{i=1}^{n}(x_i-\bar{x})\left\{\sum_{j=1}^{n} Cov[y_i, y_j]\right\}$$

となる．$i \neq j$ のとき，y_i,（$i=1, \ldots, n$）はすべて互いに独立だから $Cov[y_i, y_j]=0$ となり，$i=j$ のときは $Cov[y_i, y_i]=V[y_i]=\sigma^2$ である．よって

$$Cov\left[\sum_{i=1}^{n} y_i, \sum_{i=1}^{n}(x_i-\bar{x})y_i\right] = \sigma^2\sum_{i=1}^{n}(x_i-\bar{x}) = 0$$

となり，$Cov[\bar{y}, \hat{\beta}_1]=0$ が成り立つ.

問 8

決定係数は

$$R^2 = \frac{SSR}{SST}$$

で与えられる．ここで SSR は回帰平方和，SST は全平方和である．単回帰モデルの場合,

$$SSR = \sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2 = \sum_{i=1}^{n}\{\hat{\beta}_0+\hat{\beta}_1 x_i-(\hat{\beta}_0+\hat{\beta}_1\bar{x})\}^2 = \hat{\beta}_1^2\sum_{i=1}^{n}(x_i-\bar{x})^2$$

となり，式(9-4) から

$$SSR = \left\{\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right\}^2 \sum_{i=1}^{n}(x_i-\bar{x})^2 = \frac{\left\{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})\right\}^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}$$

となる．また，$SST=\sum_{i=1}^{n}(y_i-\bar{y})^2$ だから決定係数は

$$R^2 = \frac{\left\{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})\right\}^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\frac{1}{\sum_{i=1}^{n}(y_i-\bar{y})^2} = \left\{\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2\sum_{i=1}^{n}(y_i-\bar{y})^2}}\right\}^2$$

と表され，相関係数の 2 乗になっていることがわかる.

問 9

回帰係数を $\beta_0, \beta_1, \beta_2, \beta_3$，誤差を ε として，重回帰モデル $y=\beta_0+\beta_1 x_1+\beta_2 x_2+\beta_3 x_3+\varepsilon$ をあてはめたとする.

① $y = 100.09 + 2.34x_1 - 9.91x_2 + 0.13x_3$

② 帰無仮説は $H_0: \beta_1 = \beta_2 = \beta_3 = 0$ と表すことができる．回帰平方和を SSR とすると，この検定に対する検定統計量は

$$F = \frac{SSR/3}{SSE/16} \sim \mathrm{F}_{3,16}$$

で与えられる．$SSR = SST - SSE = 2599 - 427 = 2172$ となるから，検定統計量の実現値 f は

$$f = \frac{2172/3}{427/16} = 27.13$$

となる．自由度（3, 16）の F 分布で P 値を計算すると

```
> 1 - pf(27.13, 3, 16)
[1] 1.637168e-06
```

となり，P 値＜0.05 だから帰無仮説は棄却される．

③ 変数 x_j について，帰無仮説 $H_0: \beta_j = 0$ に対する検定統計量は

$$T_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim \mathrm{t}_{16}$$

である．x_1 について，検定統計量の実現値は

$$t_1 = \frac{2.34}{0.31} = 7.548$$

となるから，P 値は自由度 16 の t 分布を用いて

```
> 2 * (1 - pt(7.548, 16))
[1] 1.169458e-06
```

と計算できる．よって有意水準 5％で帰無仮説 $H_0: \beta_1 = 0$ は棄却される．

変数 x_2, x_3 についても同様にすればよい．変数 x_2 では検定統計量の実現値が $t_2 = -4.045$, P 値は 0.0009 となり，帰無仮説 $H_0: \beta_2 = 0$ は棄却される．変数 x_3 については，検定統計量の実現値が $t_3 = 0.542$，P 値が 0.595 となり，帰無仮説 $H_0: \beta_3 = 0$ は棄却できない．つまり，変数 x_3 については目的変数 y に有意に関連するとはいえない．

④ 決定係数 R^2 は

$$R^2 = \frac{SSR}{SST} = \frac{2172}{2599} = 0.836$$

自由度調整済み R^2 は

$$R^2_{\mathrm{adj}} = 1 - \frac{427/16}{2599/19} = 0.805$$

問 10

速度 speed を x，制動距離 dist を y で表すことにする．

① 散布図

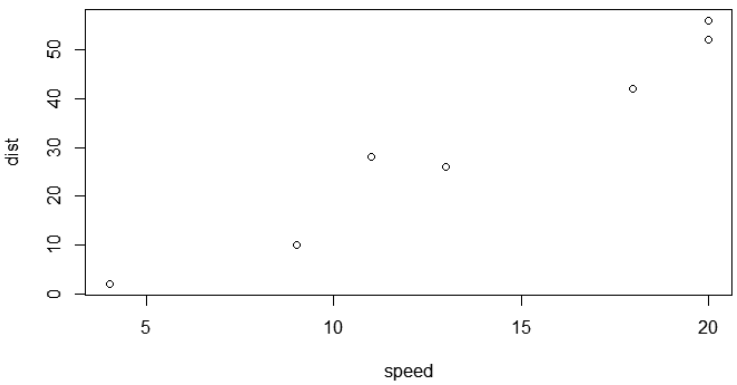

相関係数

速度の平均 $\bar{x}=13.57$，制動距離の平均 $\bar{y}=30.86$ だから

$$\sum_{i=1}^{7}(x_i-\bar{x})(y_i-\bar{y})=(4-13.57)(2-30.86)+\cdots+(20-13.57)(56-30.86)=728.6$$

$$\sum_{i=1}^{7}(x_i-\bar{x})^2=(4-13.57)^2+\cdots+(20-13.57)^2=221.7$$

$$\sum_{i=1}^{7}(y_i-\bar{y})^2=(2-30.86)^2+\cdots+(56-30.86)^2=2503$$

と計算でき，相関係数は

$$\frac{728.6}{\sqrt{221.7\times 2503}}=0.978$$

② 式(9-4) から，

$$\hat{\beta}_1=\frac{\sum_{i=1}^{7}(x_i-\bar{x})(y_i-\bar{y})}{\sum_{i=1}^{7}(x_i-\bar{x})^2}=\frac{728.6}{221.7}=3.286$$

$$\hat{\beta}_0=\bar{y}-\hat{\beta}_1\bar{x}=30.86-3.286\times 13.57=-13.73$$

これより予測値は $\hat{y}_i=-13.73+3.286x_i$ で計算でき，

$$-0.586,\ 15.844,\ 22.416,\ 28.988,\ 45.418,\ 51.990,\ 51.990,$$

となる．したがって残差 $\hat{\varepsilon}_i=y_i-\hat{y}_i$ は

$$2.586,\ -5.844,\ 5.584,\ -2.988,\ -3.418,\ 0.010,\ 4.010$$

と計算できるので，式(9-5) から

$$\hat{\sigma}^2=\frac{1}{7-2}\sum_{i=1}^{7}\hat{\varepsilon}_i^2=\frac{1}{5}(2.586^2+\cdots+4.010^2)=21.74$$

③ 帰無仮説 $H_0:\beta_1=0$ に対する検定統計量は

$$T=\frac{\hat{\beta}_1}{\sqrt{\hat{V}[\hat{\beta}_1]}}\sim t_5$$

で与えられる．分母の分散は式(9-6b)

$$V[\hat{\beta}_1] = \frac{\sigma^2}{\sum_{i=1}^{7}(x_i - \bar{x})^2}$$

で σ^2 に推定値 $\hat{\sigma}^2$ を代入することで得られ，

$$\hat{V}[\hat{\beta}_1] = \frac{\hat{\sigma}^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{21.74}{221.7} = 0.098$$

となる．よって検定統計量の実現値は

$$t = \frac{3.286}{\sqrt{0.098}} = 10.50$$

となる．自由度 5 の t 分布を用いて P 値を求めると 0.00014 となり，有意水準 5%で帰無仮説は棄却される．

④ 予測値の式 $\hat{y} = -13.73 + 3.286x$ で x に $x_0 = 15$ を代入して，このときの予測値は $\hat{y}_0 = 35.56$ 毎時となる．$\hat{y}_0$ の分散の値は

$$\hat{V}[\hat{y}_0] = \hat{\sigma}^2\left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}\right] = 21.74 \times \left[\frac{1}{7} + \frac{(15 - 13.57)^2}{221.7}\right] = 3.306$$

と計算され，95%信頼区間は

$$\hat{y}_0 \pm t_{a/2}(n-2)\sqrt{\hat{V}[\hat{y}_0]} = 35.56 \pm t_{0.025}(5)\sqrt{3.306} = [30.89, 40.23]$$

となる．

予測区間については，

$$\hat{V}[\varepsilon_0] = \hat{\sigma}^2\left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}\right] = 21.74 + 3.36 = 25.1$$

と計算できるから，

$$\hat{y}_0 \pm t_{a/2}(n-2)\sqrt{\hat{V}[\varepsilon_0]} = 35.56 \pm t_{0.025}(5)\sqrt{25.1} = [22.68, 48.44]$$

となる．

⑤ 全平方和 $SST = \sum_{i=1}^{7}(y_i - \bar{y})^2$ は①で 2503 と得られている．誤差平方和 $SSE = \sum_{i=1}^{7}(y_i - \hat{y}_i)^2$ は，②で求めた残差を用いて

$$SSE = \sum_{i=1}^{7}(y_i - \hat{y}_i)^2 = 2.586^2 + \cdots + 4.010^2 = 108.7$$

となる．したがって決定係数は

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{108.7}{2503} = 0.957$$

⑥

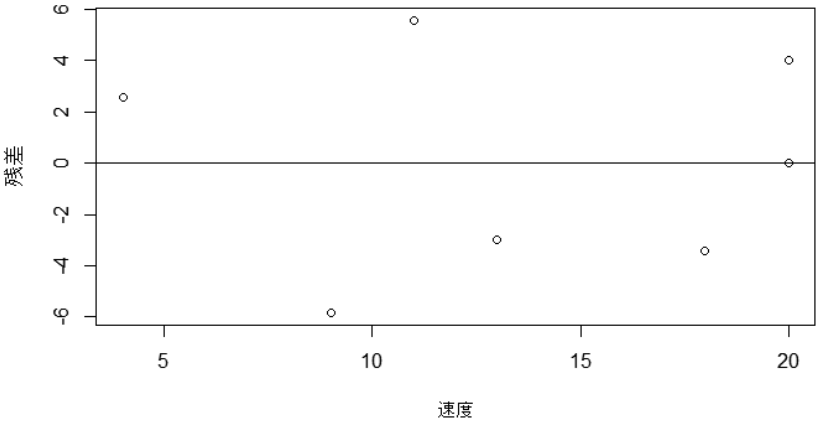

問 11

① データの読み込み，散布図の作成と相関係数の計算は R で次のようにして実行できる．

```
> data(cars)
>
> plot(cars$speed, cars$dist, xlab = "Speed", ylab = "Dist")
> cor(cars$speed, cars$dist)
[1] 0.8068949
```

散布図

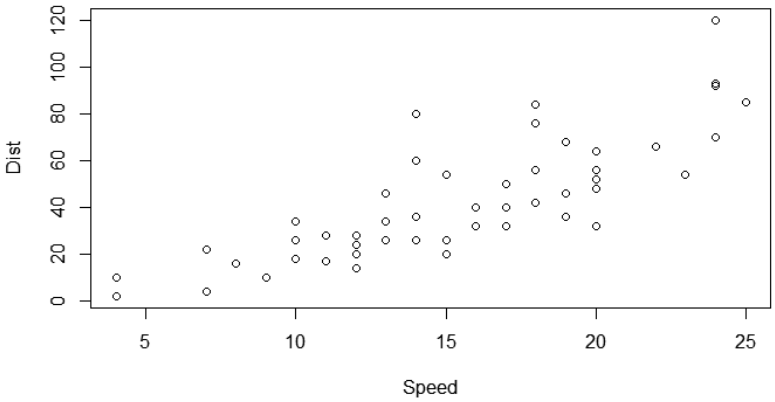

相関係数：0.807

② R による単回帰モデルのあてはめ結果は次のようになる．

```
> fit1 <- lm(dist ~ speed, data = cars)
> summary(fit1)

Call:
lm(formula = dist ~ speed, data = cars)

Residuals:
    Min      1Q  Median      3Q     Max 
-29.069  -9.525  -2.272   9.215  43.201 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) -17.5791     6.7584  -2.601   0.0123 *  
speed         3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511,	Adjusted R-squared:  0.6438 
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12
```

この結果から，

$$\hat{\beta}_0 = -17.58, \qquad \hat{\beta}_1 = 3.93, \qquad \hat{\sigma}^2 = 15.38^2 = 236.5$$

③　②の結果から $H_0 : \beta_1 = 0$ に対する P 値は $1.49 \times 10^{-12} < 0.05$ であり，帰無仮説は棄却される．

④　予測値と 95％信頼区間の結果は次のようにして得られる．

```
> predict(fit1, newdata = data.frame(speed = 15), interval = "confidence")
       fit      lwr      upr
1 41.40704 37.02115 45.79292
```

予測値は 41.4，95％信頼区間は［37.0, 45.8］である．また，95％予測区間は次のようにして［10.2, 72.6］と計算できる．

```
> predict(fit1, newdata = data.frame(speed = 15), interval = "prediction")
       fit      lwr      upr
1 41.40704 10.17482 72.63925
```

⑤　②の結果から決定係数は 0.651 である．

⑥　予測値を横軸に取った残差プロットを次のようにして描くことができる．

```
> plot(fit1$fitted.values, fit1$residuals, xlab = "予測値", ylab = "残差")
> abline(h = 0)
```

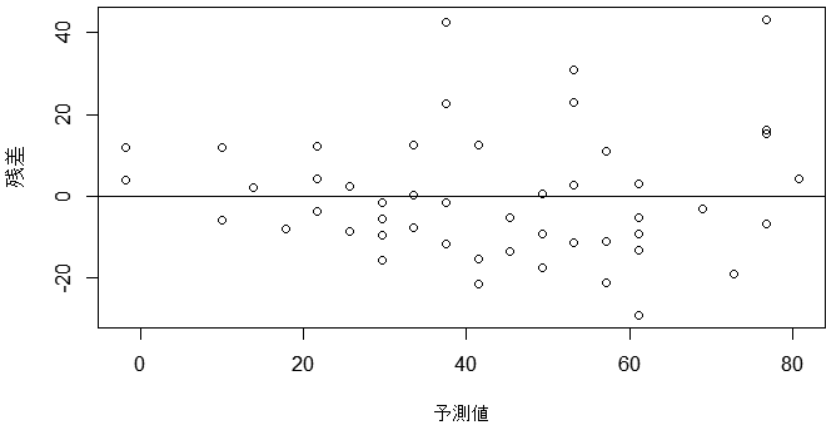

残差プロットを見ると，予測値が大きくなるにつれ（速度が大きくなるにつれ）残差のばらつきも大きくなる傾向がみられる．そこで制動距離を対数変換したモデル $\log(\mathrm{dist}) = \beta_0 + \beta_1 \times (\mathrm{speed}) + \varepsilon$ をあてはめてみると次のようになる．

```
> fit2 <- lm(log(dist) ~ speed, data = cars)
> summary(fit2)

Call:
lm(formula = log(dist) ~ speed, data = cars)

Residuals:
     Min       1Q   Median       3Q      Max
-1.46604 -0.20800 -0.01683  0.24080  1.01519

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.67612    0.19614   8.546 3.34e-11 ***
speed        0.12077    0.01206  10.015 2.41e-13 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.4463 on 48 degrees of freedom
Multiple R-squared:  0.6763,    Adjusted R-squared:  0.6696
F-statistic: 100.3 on 1 and 48 DF,  p-value: 2.413e-13
```

このモデル fit2 では $R^2 = 0.676$ となり，fit1 よりややあてはまりの改善がみられる．速度のほうも対数変換したモデル $\log(\mathrm{dist}) = \beta_0 + \beta_1 \times \log(\mathrm{speed}) + \varepsilon$ をあてはめてみると次のようになる．

```
> fit3 <- lm(log(dist) ~ log(speed), data = cars)
> summary(fit3)

Call:
lm(formula = log(dist) ~ log(speed), data = cars)

Residuals:
     Min       1Q   Median       3Q      Max
-1.00215 -0.24578 -0.02898  0.20717  0.88289

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.7297     0.3758  -1.941   0.0581 .
log(speed)    1.6024     0.1395  11.484 2.26e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4053 on 48 degrees of freedom
Multiple R-squared:  0.7331,    Adjusted R-squared:  0.7276
F-statistic: 131.9 on 1 and 48 DF,  p-value: 2.259e-15
```

このモデル fit3 では $R^2=0.733$ であり，あてはまりがさらに改善している．

Fit3 のモデルは $\mathrm{dist}=\mathrm{speed}^{\beta_1}e^{\beta_0}$ という関係を仮定していることを意味する．このモデルでは speed＝0 のときは dist＝0 となるが，fit1 のモデルでは speed＝0 のとき dist＝β_0，fit2 のモデルでは speed＝0 のとき dist＝e^{β_0} となる．このようにモデルの解釈の意味でも，上記 3 つのモデルの中では fit3 が最も適切であるといえる．

問 12

各変数の要約結果は次の表のようになる（連続変数は中央値［最小値，最大値］，2 値変数は人数（%））．

変数	要約値（N＝189）
出生時体重［g］	2977［709, 4990］
母親の体重［ポンド］	121［80, 250］
母親の年齢	23［14, 45］
妊娠期間中の喫煙の有無（あり）	74（39.2%）

① 重回帰モデル $\mathrm{bwt}=\beta_0+\beta_1\times\mathrm{lwt}+\beta_2\times\mathrm{age}+\beta_3\times\mathrm{smoke}+\varepsilon$ のあてはめを R で実行すると次のようになる．

```
> fit <- lm(bwt ~ lwt + age + smoke, data = birthwt)
> summary(fit)

Call:
lm(formula = bwt ~ lwt + age + smoke, data = birthwt)

Residuals:
     Min       1Q   Median       3Q      Max 
-2070.97  -431.56    12.95   521.70  1811.67 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 2362.495    300.683   7.857 3.12e-13 ***
lwt            4.016      1.720   2.335   0.0206 *  
age            7.154      9.925   0.721   0.4719    
smoke       -269.257    105.801  -2.545   0.0117 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 708.8 on 185 degrees of freedom
Multiple R-squared:  0.07039,	Adjusted R-squared:  0.05531 
F-statistic: 4.669 on 3 and 185 DF,  p-value: 0.003606
```

F 検定の結果をみると P 値＝0.0036＜0.05 であり，H_0:$\beta_1=\beta_2=\beta_3=0$ は有意水準 5％で棄却される．個々の説明変数の結果をみると，母親の体重と妊娠期間中の喫煙の有無はともに P 値＜0.05 であり，出生時の体重に有意に関連することが示唆されている．母親の体重が 1 ポンド高いと新生児の出生時体重は 4g 増加する傾向があり，母親が妊娠期間中に喫煙していると新生児の出生時体重は 269g 低下する傾向がある．

② 3 つの説明変数間の相関係数は次のように計算される．強い相関関係はみられない．

```
> cor(birthwt[, c("lwt", "age", "smoke")])
              lwt         age       smoke
lwt    1.00000000  0.18007315 -0.04417908
age    0.18007315  1.00000000 -0.04434618
smoke -0.04417908 -0.04434618  1.00000000
```

VIF は R の car パッケージにある vif 関数で調べることができる．

```
> library(car)
> vif(fit)
     lwt      age    smoke 
1.034917 1.034932 1.003332 
```

この値からも，多重共線性は生じていないと判断できる．

③ 残差プロットを作成すると図のようになる．右はスチューデント化残差を縦軸に取った場合である．予測値によらず 0 の周辺で同程度のバラツキで散らばっており，正規性，等分散性の仮定に問題はないと判断できる．

```
> par(mfcol = c(1, 2))
> plot(fit$fitted.values, fit$residuals, xlab = "予測値", ylab = "残差")
> abline(h = 0, lty = 2)
> plot(fit$fitted.values, rstudent(fit), xlab = "予測値", ylab = "スチューデント化残差")
> abline(h = c(-2, 0, 2), lty = 2)
> par(mfcol = c(1, 1))
```

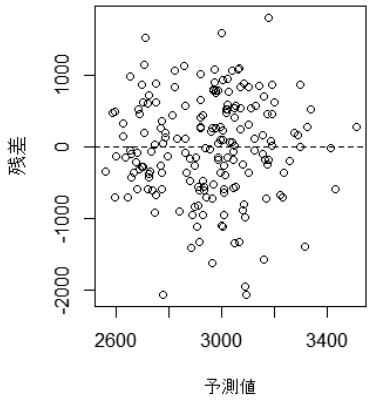

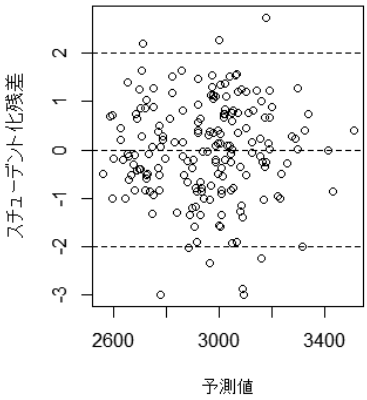

④　出生時体重の予測値と 95％信頼区間は次のように計算できる．1 行目が喫煙なし，2 行目が喫煙ありのときの結果である．

```
> newdata <- data.frame(lwt = 120, age = 25, smoke = c(0,1))
> predict(fit, newdata = newdata, interval = "confidence")
       fit      lwr      upr
1 3023.204 2882.759 3163.648
2 2753.947 2583.074 2924.819
```

95％予測区間の結果は次のとおりである．

```
> predict(fit, newdata = newdata, interval = "prediction")
       fit      lwr      upr
1 3023.204 1617.875 4428.532
2 2753.947 1345.252 4162.641
```