## 第 10 章

### 問 1

ロジスティック関数$f(z)$ は次のように与えられる．

$$f(z)=\frac{1}{1+e^{-z}} \quad (-\infty<z<\infty)$$

この関数を $z$ で微分すると

$$f'(z)=\frac{e^{-z}}{(1+e^{-z})^2}=f(z)[1-f(z)]>0$$

したがって$f(z)$ は単調増加関数である．$f'(z)$をさらに $z$ で微分すると

$$f''(z)=f'(z)[1-f(z)]-f(z)f'(z)=f'(z)[1-2f(z)]$$

となり，$f''(z)=0$ とすると$f(z)=1/2$ が得られる．よって $z=0$ のとき$f''(z)=0$ となり，変曲点は $(0, 1/2)$ である．

### 問 2

尤度関数は標本（$y_1, \dots, y_n$）が得られる確率$P(Y_1=y_1, \dots, Y_n=y_n)$ を分布パラメータの関数と考えたものである．$y_1, \dots, y_n$ は互いに独立に得られており，すべてベルヌーイ分布 $\mathrm{B}(1, p)$ に従うから，尤度関数は

$$\begin{aligned}L(p)&=P(Y_1=y_1, \dots, Y_n=y_n)=P(Y_1=y_1)\cdots P(Y_n=y_n)=p^{y_1}(1-p)^{1-y_1}\cdots p^{y_n}(1-p)^{1-y_n}\\&=p^{\sum_{i=1}^n y_i}(1-p)^{n-\sum_{i=1}^n y_i}\end{aligned}$$

となる．$x=\sum_{i=1}^n y_i$ とおくと，対数尤度は

$$l(p)=x\log p+(n-x)\log(1-p)$$

となり，これを $p$ で微分すると

$$l'(p)=\frac{x}{p}-\frac{n-x}{1-p}$$

$l'(p)$を解くと，$p$ の最尤推定値が

$$\hat{p}=\frac{x}{n}$$

と得られる．

### 問 3

ロジスティック回帰モデルは

$$\log\frac{P(Y=1|x_1, x_2)}{1-P(Y=1|x_1, x_2)}=\beta_0+\beta_1x_1+\beta_2x_2$$

と表すことができる．

① 推定されたロジスティック回帰モデル

$$\log\frac{P(Y=1|x_1, x_2)}{1-P(Y=1|x_1, x_2)}=-9.10+0.24x_1+0.10x_2$$

② 糖尿病に関するオッズ比 $e^{\beta_1}$ の推定値は $e^{\hat{\beta}_1}=e^{0.24}=1.271$ となる．$\beta_1$ の 95%信頼区間は

$$0.24\pm1.96\times0.24=(-0.230,\ 0.710)$$

と計算できるから，オッズ比 $e^{\beta_1}$ の 95%信頼区間は $(e^{-0.230}, e^{0.710})=(0.795, 2.034)$ となる．

③ 検定統計量の実現値は $z_1=0.24/0.24=1<1.96$ となるから，有意水準 5%で帰無仮説 $H_0:\beta_1=0$ を棄却することはできない．したがって，糖尿病により 30 日後の死亡リスクが有意に増加したり減少したりするとはいえない．

④ 年齢に関するオッズ比 $e^{\beta_2}$ の推定値は $e^{\hat{\beta}_2}=e^{0.10}=1.105$ となる．$\beta_2$ の 95%信頼区間は

$$0.10+\pm1.96\times0.01=(0.080,\ 0.120)$$

と計算できるから，オッズ比 $e^{\beta_2}$ の 95%信頼区間は $(e^{0.080}, e^{0.120})=(1.083, 1.127)$ となる．

⑤ 検定統計量の実現値は $z_2=0.10/0.01=10>1.96$ となるから，有意水準 5%で帰無仮説 $H_0:\beta_2=0$ は棄却される．したがって，年齢は 30 日後の死亡に有意に関連しているといえる．④でオッズ比の推定値が 1.105 と得られていることから，年齢が高いほど 30 日後の死亡リスクは増加するといえる．

**問 4**

① $\beta_0=-1, \beta_1=1.5$ のとき，ロジスティック回帰モデルは

$$\log\frac{p_i}{1-p_i}=-1+1.5x_i$$

と表されるから，予測確率は

$$p_i=\frac{1}{1+\exp(-(-1+1.5x_i))}$$

で計算できる．喫煙ありの対象の予測確率は

$$p_i=\frac{1}{1+e^{-0.5}}=0.622\quad(i=1, 2, 3)$$

喫煙なしの対象の予測確率は

$$p_i=\frac{1}{1+e}=0.269\quad(i=4, 5, 6)$$

② 対象 $i$ の尤度は

$$L_i(\beta_0, \beta_1)=P(Y_i=y_i|x_i)=p_i^{y_i}(1-p_i)^{1-y_i}$$

ただし

$$p_i=\frac{1}{1+\exp(-(\beta_0+\beta_1x_i))}$$

である．したがって，全対象での尤度は

$$L(\beta_0, \beta_1)=\prod_{i=1}^{6}L_i(\beta_0, \beta_1)=\prod_{i=1}^{6}p_i^{y_i}(1-p_i)^{1-y_i}$$

となり，対数尤度は次のように表すことができる．

$$l(\beta_0, \beta_1)=\sum_{i=1}^{6}\{y_i\log p_i+(1-y_i)\log(1-p_i)\}=\sum_{i=1}^{6}\left\{y_i\log\frac{p_i}{1-p_i}+\log(1-p_i)\right\}$$

$$= \sum_{i=1}^{6} \left\{ y_i(\beta_0 + \beta_1 x_i) + \log \frac{\exp(-(\beta_0 + \beta_1 x_i))}{1 + \exp(-(\beta_0 + \beta_1 x_i))} \right\}$$

$$= \sum_{i=1}^{6} \{(y_i - 1)(\beta_0 + \beta_1 x_i) - \log[1 + \exp(-(\beta_0 + \beta_1 x_i))]\}$$

③　まず，②の対数尤度で $\{x_i, y_i\}_{i=1}^{n}$ の値を代入する．$y=1$ の対象では $\Sigma$ の中の第 1 項が 0 となるから，

$$l(\beta_0, \beta_1) = -2\log[1 + e^{-(\beta_0+\beta_1)}] - (\beta_0 + \beta_1) - \log[1 + e^{-(\beta_0+\beta_1)}] - \log[1 + e^{-\beta_0}]$$
$$-2[\beta_0 + \log[1 + e^{-\beta_0}]]$$
$$= -3\log[1 + e^{-(\beta_0+\beta_1)}] - (3\beta_0 + \beta_1) - 3\log[1 + e^{-\beta_0}]$$

$\beta_0$ の最尤推定値 $\hat{\beta}_0$ を代入すると

$$l(\hat{\beta}_0, \beta_1) = -3\log[1 + e^{-(\hat{\beta}_0+\beta_1)}] - (3\hat{\beta}_0 + \beta_1) - 3\log[1 + e^{-\hat{\beta}_0}]$$

となる．これを $\beta_1$ で微分すると

$$\frac{dl(\hat{\beta}_0, \beta_1)}{d\beta_1} = -3 \cdot \frac{-e^{-(\hat{\beta}_0+\beta_1)}}{1 + e^{-(\hat{\beta}_0+\beta_1)}} - 1$$

$dl(\hat{\beta}_0, \beta_1)/d\beta_1 = 0$ とすると，

$$3e^{-(\hat{\beta}_0+\beta_1)} = 1 + e^{-(\hat{\beta}_0+\beta_1)}$$

$$e^{-(\hat{\beta}_0+\beta_1)} = \frac{1}{2}$$

$$\therefore\ \hat{\beta}_1 = \log 2 - \hat{\beta}_0 = 1.386$$

④　帰無仮説 $H_0 : \beta_1 = 0$ に対する検定統計量は

$$Z = \frac{\hat{\beta}_1}{\mathrm{SE}(\hat{\beta}_1)} \sim \mathrm{N}(0,1)$$

である．$\hat{\beta}_1 = 1.386$, $SE(\hat{\beta}_1) = 1.732$ より検定統計量の実現値は $z = 1.386/1.732 = 0.800 < 1.96$ だから，有意水準 5％で帰無仮説を棄却することはできない（P 値を計算すると 0.423）．

$\beta_1$ の 95％信頼区間が

$$\hat{\beta}_1 \pm 1.96SE(\hat{\beta}_1) = (-2.009, 4.781)$$

と計算できることから，肺がんの発生確率に関するオッズ比 $e^{\beta_1}$ の推定値は $e^{\hat{\beta}_1} = 3.999$，95％信頼区間は

$$(e^{-2.702}, e^{4.088}) = (0.134, 119.2)$$

**問 5**

ロジスティック回帰モデルは

$$\mathrm{logit}\, P(\mathrm{low} = 1 \mid \mathrm{lwt}, \mathrm{age}, \mathrm{smoke}) = \beta_0 + \beta_1(\mathrm{lwt}) + \beta_2(\mathrm{age}) + \beta_3(\mathrm{smoke})$$

と表すことができる．

①　R で上のロジスティック回帰モデルをあてはめた結果は次のようになる．

```
> library(MASS)
>
> data(birthwt)
>
> fit <- glm(low ~ lwt + age + smoke, data = birthwt, family = binomial)
> summary(fit)

Call:
glm(formula = low ~ lwt + age + smoke, family = binomial, data = birthwt)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.2829  -0.8650  -0.6938   1.2624   2.0103

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept)  1.368225   1.014262   1.349   0.1773
lwt         -0.012139   0.006135  -1.979   0.0479 *
age         -0.038995   0.032726  -1.192   0.2334
smoke        0.670764   0.325878   2.058   0.0396 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 234.67  on 188  degrees of freedom
Residual deviance: 222.88  on 185  degrees of freedom
AIC: 230.88

Number of Fisher Scoring iterations: 4
```

母親の体重 lwt は P 値＝0.0479 であり，有意水準 5％で低出生体重に有意に関連している．$\hat{\beta}_1<0$ だから，母親の体重が大きいほど低出生体重のリスクは低くなるといえる．母親の年齢 age は P 値＝0.2334 であり，低出生体重のリスクに有意に関連しているとはいえない．喫煙の有無 smoke は P 値＝0.0396 であり，低出生体重のリスクに有意に関連しているといえる．$\hat{\beta}_3>0$ だから，喫煙ありの母親のほうが低出生体重のリスクが高いといえる．

② 各説明変数についてのオッズ比と 95％信頼区間は次のようにして計算できる．

```
> exp(fit$coef)
(Intercept)         lwt         age       smoke
  3.9283727   0.9879348   0.9617559   1.9557304
> exp(confint.default(fit))
                2.5 %     97.5 %
(Intercept) 0.5381107 28.6783220
lwt         0.9761269  0.9998856
age         0.9020038  1.0254663
smoke       1.0325744  3.7042189
```

母親の体重：オッズ比 0.988, 95％信頼区間（0.976, 1.000）

母親の年齢：オッズ比 0.962, 95％信頼区間（0.902, 1.025）

喫煙の有無：オッズ比 1.956, 95％信頼区間（1.033, 3.704）

③ 母親が 25 歳で体重 120 ポンドのとき，喫煙者の場合と非喫煙者の場合で予測確率は次のように計算できる．

```
> # 喫煙者
> 1 / (1 + exp(-sum(fit$coef * c(1, 120, 25, 1))))
[1] 0.4031155
> # 非喫煙者
> 1 / (1 + exp(-sum(fit$coef * c(1, 120, 25, 0))))
[1] 0.2566861
```